

שני מודלים של AI נכנסים לאותו מרחב

איך הוכחתי שרשתות נוירונים מדברות בסתר את אותה שפה — והשתמשתי בזה כדי שאייפון ושרת יחלקו אינדקס חיפוש אחד

הכול התחיל משאלה שנשמעת נאיבית: אפשר לקחת שכבות ממודלים שונים ולהרכיב מהן מודל חדש, בסגנון פרנקנשטיין, בלי לאמן? התשובה הקצרה היא לא — והסיבה היא אחת העובדות היפות בלמידה עמוקה. התשובה הארוכה הפכה לפרויקט הגמר שלי: ניסוי אמיתי, על GPU חינמי ב-Colab, שמסתיים בקובץ של 0.79 מגה-בייט שעושה עבודה אמיתית באפליקציה אמיתית.

הפרדוקס: מוחות זהים, חיווט זר

לרשתות נוירונים יש תכונה מוזרה בשם סימטריית פרמוטציה. ערבבו את סדר הנוירונים בשכבה (וחווטו מחדש בהתאם) — תקבלו בדיוק את אותה התנהגות ממספרים שונים לחלוטין. לשכבה אחת יש יותר סידורי משקולות שקולים מאשר אטומים ביקום. שני אימונים — אפילו של אותו מודל — נוחתים על סידורים שונים. להשוות משקולות גולמיות בין מודלים בלתי תלויים זה כמו להשוות שני ספרי טלפונים שממוינים לפי כללים שונים: לרשומה מספר 500 אין שום דבר משותף. השתלת שכבות בין מודלים מייצרת רעש טהור.

אבל הנה הטוויסט. משקולות הן ה'איך' של החישוב. מה שמחושב — המפה הפנימית של אילו מושגים קרובים לאילו — זה סיפור אחר. גוף מחקר הולך וגדל (CKA, Git Re-Basin), והשערת הייצוג האפלטוני בעלת השם (הנהדר) מרמז שמודלים מאומנים היטב מתכנסים כולם לאותה מפה, רק משורטטת במערכות קואורדינטות שונות. כמו שני קרטוגרפים שמעולם לא נפגשו, שממפים את אותה עיר כשהצפון מצביע לכיוונים שונים.

אם זה נכון, תרגום בין שני מודלים לא אמור לדרוש שום אימון מחדש. הוא אמור לדרוש בדיוק מטריצה אחת — החלפת קואורדינטות.

הניסוי: שני זרים, מבחן אחד


כדי לבחון זאת כמו שצריך בחרתי שני מודלים בלי שום דבר משותף: GPT-2 (OpenAI, 2019), אומן על WebText ו-Pythia-160M (EleutherAI, 2023), אומן על The Pile. מעבדות, ארכיטקטורות, tokenizers, דאטה ותקופות — הכול שונה. הרצתי את אותם 10,000 קטעי ויקיפדיה דרך שניהם, שמרתי את האקטיביציות של כל שכבה, ושאלתי שתי שאלות. ראשית: האם מבני הדמיון הפנימיים תואמים (במדד CKA, שמתעלם במכוון מבחירת קואורדינטות)? שנית, והמכרעת: האם מטריצה אחת, מותאמת ברגרסיית ridge קלאסית במילי-שניות, מתרגמת את הייצוגים של האחד לשל השני?

והכי חשוב — הכול הושווה מול ביקורת: אותה ארכיטקטורה עם משקולות אקראיות, ללא אימון. ה-baseline הזה הוא מה שהופך מספרים לראיות — הוא מודד כמה דמיון מקבלים 'בחינם' מהארכיטקטורה לבדה, כך שכל מה שמעליו הוא טביעת האצבע של הלמידה.

התוצאות היו חד-משמעיות. דמיון ה-CKA בין המודלים המאומנים רץ פי 4-5 מעל הביקורת, מרוכז באלכסון — שכבות מוקדמות תואמות מוקדמות, אמצעיות לאמצעיות. ומטריצת התרגום הגיעה ל- R^2 של 0.70-0.80 בשכבות האמצעיות והמאוחרות, בעוד הביקורת דעכה לאפס. שתי העקומות אף משופעות בכיוונים הפוכים: הלמידה בונה מבנה משותף שכבה אחר שכבה; האקראיות הורסת אותו שכבה אחר שכבה.

אבל זה כמעט לא עבד — והכישלון הוא החלק האהוב עליי. הריצה הראשונה הראתה R^2 תקוע סביב 0.5, מתחת לסף ההצלחה שהגדרתי לעצמי. ההשערה נראתה חצי-נכונה. לפני שכתבתי את המסקנה הזו, בדקתי את החשבון: התאמתי מטריצה של 590 אלף פרמטרים על 1,200 דוגמאות — 1.6 דגימות

לממד. רגרסיה מורעבת ברמה כזו לא נעשית רועשת; היא משקרת בשקט, באופן שיטתי, בכיוון אחד. שינוי קוד אחד (פי 6 דאטה) וחמש-עשרה דקות GPU אחר כך, אותו צינור בדיוק הניב R^2 של 0.74-0.80:




אותו ניסוי, אותו קוד — 1,646 דגימות (שמאל) מול 10,000 (ימין). הכהה — תרגום אמיתי בין מודלים; האפור — ביקורת לא מאומנת; המקווקו — סף ההצלחה.

התמורה: אינדקס אחד לטלפון ולשרת

הנה למה זה חשוב מעבר לפילוסופיה. אני בונה אפליקציה מולטימודלית דו-שכבתית: אייפון מריץ מקודד תמונה זעיר (MobileCLIP, כ-30MB) כדי שתמונות יאונדקסו אופליין ובפרטיות; שרת מריץ מקודד גדול (SigLIP 2, כ-1.5GB) לחיפוש. שניהם הופכים תמונות לוקטורים — במרחבים זרים הדדית. בלי תרגום, חיפוש בתמונות שאונדקסו בטלפון מקבל בדיוק את ציון המקריות: Recall@1 של 0.001 על אלף תמונות. הטלת מטבע בין אלף, פשוטו כמשמעו.

אז התאמתי את המטריצה: 768×512 מספרים, 1.6 מגה-בייט, בצורה סגורה, על 3,000 זוגות תמונה מ-COCO. על תמונות held-out: המטריצה מעלה את האחזור ממקריות ל-95%-98% מאיכות המודל הגדול ב-Recall@5 ו-10@1. אבל Recall@1 נחת על 88.4% מהתקרה — קצת מתחת לשער ה-90% שלי. הרגע השני-מתחת-ליעד בפרויקט. לפי הפלייבוק ניסיתי מתרגם חזק יותר: רשת נויורנים אמיתית, שממטבת ישירות את מטרת האחזור, עם פי עשרה פרמטרים. היא ניצחה את המטריצה ב-0.003 — כלום סטטיסטי. הכישלון הזה הוא הממצא: הקשר בין שני המרחבים הוא, לכל צורך מעשי, ליניארי במדויק, והפער שנותר אינו כשל תרגום — הוא פירוט שהמקודד הזעיר בטלפון מעולם לא קלט. אי אפשר לתרגם את מה שלא קיים. (סימטריה יפה: בניסוי A, יותר דאטה הוכיח שהמפה הליניארית טובה משנראתה; כאן יותר קיבולת הוכיחה שהיא כבר אופטימלית.)



כל הגרסאות במבט אחד: העמודות האדומות — כך נראה חיפוש בין-מודלי ללא תרגום. מקריות מדויקת.

המטריצה נשלחת עכשיו כחבילת Core ML של 0.79 מגה-בייט. האיפון מקודד תמונה, מכפיל במטריצה אחת על ה-Neural Engine, וכותב לאותו אינדקס Qdrant שהשרת מחפש בו. תמונות הופכות לברות-חיפוש בלי לעזוב את המכשיר. אינדקס אחד, שתי שכבות, אפס אימון מחדש.

ואז צפיתי בזה עובד

מספרים זה דבר אחד; לצפות זה דבר אחר. בניתי דמו אינטראקטיבי קטן: שש תמונות חיות על ה'שרת' (מאונדקסות במודל הגדול), ואני מעלה תמונה של ציפור אדומה מהמחשב שלי לצד ה'טלפון'. מסלול הטלפון — המקודד הזעיר ועוד המטריצה שלי — מאנדקס אותה ב-39 מילי-שניות ואף מקטלג אוטומטית: 'a red bird perched on a branch'. ואז אני מקליד חיפוש: singing red bird. התמונה שלי חוזרת במקום הראשון — יושבת באותה רשימת תוצאות עם תמונות השרת, מדורגת על ידי אותו אינדקס, נמצאת על ידי מודל טקסט שמעולם לא שמע על המקודד של הטלפון. החיפוש עצמו אורך 0.08 מילי-שניות מקומית; ניתוב אותו חיפוש דרך סבב רשת סלולרית (מדומה) אורך 150. אותו אינדקס, אותה מתמטיקה — הרשת היא ההבדל היחיד. צילום המסך הזה הוא כל הפרויקט.

ואז השתמשתי בזה

מספרים משכנעים בוחנים; דמואים משכנעים את כל השאר. אז בניתי ארגז חול אינטראקטיבי: שש תמונות מאונדקסות 'בצד השרת' עם SigLIP מקורי, וכפתור העלאה שמגלם את גלריית הטלפון. העליתי תמונה של ציפור אדומה. מסלול הטלפון קידד אותה ב-39 מילי-שניות (MobileCLIP ועוד המטריצה, בדיוק כפי שחבילת ה-Core ML מחשבת), מודל כיתוב כתב 'a red bird perched on a branch', והווקטור הצטרף לאותו אינדקס של תמונות השרת. ואז הקלדתי חיפוש: singing red bird. התמונה שאונדקסה בטלפון חזרה ראשונה — מדורגת באותה רשימה עם תמונות שאונדקסו בשרת, על ידי מקודד טקסט שמעולם לא שמע על MobileCLIP או על המתאם. החיפוש עצמו לקח 0.08 מילי-שניות מקומית מול 150 בסבב השרת המדומה: אותו אינדקס, אותה מתמטיקה — הרשת היא ההבדל היחיד שהשתמש מרגיש. אינדקס אחד, שתי שכבות, וציפור אחת.

מה באמת למדתי

שלווה דברים נשאים איתי. ראשית, השיטה המדעית זולה להפתיע: השערה, ביקורת, ספי הפרכה, רפליקציה של שלווה קווי מחקר מפורסמים — הכול בפחות משעת GPU אחת. שנית, baselines הם הכול: כל מספר בפרויקט מקבל משמעות רק ביחס לביקורת שלו, והבאג הגדול ביותר שלי ייצר מסקנות

שגויות סבירות-למראה, לא הודעות שגיאה. ושלישית, והמדהים מכולם: רשתות נירונים שאומנו באופן בלתי תלוי באמת מגלות את אותו מבנה של העולם. הן רק מתייקות אותו בקואורדינטות שונות — ושער החליפין בין כל שתיים מהן הוא מטריצה אחת. יש משהו כמעט אפלטוני בלשלוח את העובדה הזו לייצור.