

# התכנסות ייצוגים ברשתות נוירונים שאומנו באופן בלתי תלוי

מהשערה תיאורטית ועד מתאם (Adapter) פרוס בין מודלים, למערכת אחזור דו-שכבתית מובייל/שרת — פרויקט גמר, קורס מומחה AI, יולי 2026

**תקציר.** הפרויקט בוחן את ההשערה שרשתות נוירונים מאומנות היטב, שפותחו באופן בלתי תלוי, לומדות את אותם ייצוגים פנימיים עד כדי טרנספורמציה ליניארית — ולאחר האישוש הופך את התיאוריה לרכיב מערכת עובד. ניסוי A מדגים, באמצעות ניתוח דמיון CKA ותפירה ליניארית (stitching) בצורה סגורה, ש-אתחול, tokenizer, דאטה או מעבדה משותפים — חולקים עד 80% מהשונות הייצוגית הנגישה ליניארית בשכבות תואמות, לעומת baseline ביקורת עם משקולות אקראיות. ניסוי B מיישם את התוצאה: מטריצת ridge בודדת בגודל  $768 \times 512$  (1.6MB), מותאמת בצורה סגורה בשניות) מתרגמת embeddings של המקודד הנייד MobileCLIP-S1 אל מרחב המקודד השרתי SigLIP 2, תוך שימור 95%-98% מאיכות אחזור טקסט-לתמונה ב-Recall@5/@10 על COCO, מול baseline ללא מתאם ברמת מקריות מוחלטת. השוואת MLP מבוקרת מראה שהקשר בין המרחבים ליניארי במדויק. המתאם יוצא כחבילת Core ML במשקל 0.79MB, ומאפשר אינדקס וקטורי משותף אחד (Qdrant) המשרת שכבת iPhone ושכבת שרת של אפליקציית חיפוש מולטימודלית.

# 1. מבוא: פרויקט מחקר שפותר בעיה אמיתית

הפרויקט נולד משאלה הנדסית שעולה בכל מערכת מרובת-מודלים: האם רכיבים הבנויים סביב רשתות שונות יכולים לעבוד יחד ללא אימון מחדש? המערכת המדוברת היא אפליקציה מולטימודלית דו-שכבתית: iPhone שמריץ מקודד תמונה קטן ומהיר (MobileCLIP-S1, כ-30MB) לאינדוקס תמונות אופליין, פרטי, על המכשיר; ושרת שמריץ מקודד גדול ומדויק (SigLIP 2, כ-1.5GB) לחיפוש ועיבוד כבד. שני המקודדים ממפים תמונות לווקטורים — אך המרחבים שלהם זרים זה לזה: קוסינוס בין וקטור MobileCLIP לווקטור SigLIP של אותה תמונה חסר משמעות, ולכן וקטורים משתי השכבות אינם יכולים לחלוק אינדוקס חיפוש. העקיפות הנאיביות יקרות כולן: אינדוקס כפול, העלאת כל תמונה לשרת (הרס הפרטיות והאופליין), או הרצת המודל הגדול בטלפון (הרס זמן התגובה והסוללה).

השאלה המדעית שמתחת: האם שני המרחבים הם בעצם אותו מרחב בקואורדינטות שונות? אם מודלים בלתי תלויים מתכנסים למבנה ייצוגי משותף, מפה נלמדת קטנה — אידיאלית מטריצה ליניארית אחת — תתרגם ביניהם, והבעיה ההנדסית מתאדה. לכן לפרויקט שני חלקים: ניסוי מדעי מבוקר (ניסוי A) ויישום מעשי על מודלי הייצור המדויקים, עד ארטיפקט iOS פרוס (ניסוי B).

## 2. רקע ותיאוריה

### 2.1 מדוע אי אפשר להשוות או להשתיל משקולות גולמיות

רשתות נוירונים מקיימות סימטריית פרמוטציה: שינוי סדר הנוירונים בשכבה, יחד עם חיווט מחדש עקבי של המטריצות הסמוכות, נותן רשת שמחשבת בדיוק את אותה פונקציה עם ערכי משקולות שונים לגמרי. לשכבה של 1,000 נוירונים יש 1000! תצורות שקולות פונקציונלית, וסימטריות סיבוב וסקיילינג מרחיבות עוד. שני אימונים — אפילו של אותה ארכיטקטורה עם seed שונה — נוחתים על איברים שונים של מחלקת השקילות. לכן מיצוע או השתלה של משקולות בין מודלים בלתי תלויים חסרי משמעות, ולכן מיזוג משקולות (SLERP, TIES, DARE, frankenmerging) עובד רק בין fine-tunes של checkpoint בסיס משותף.

### 2.2 מדוע ייצוגים בכל זאת מתכנסים

משקולות הן ה'איך'; ייצוגים (אקטיבציות על דאטה) הם ה'מה'. כל הדאטה — טקסט, תמונות, אודיו — הן הטלות של מציאות אחת, ומודל שדוחס ומנבא אותה אופטימלית נדחף לשחזר את המבנה הסטטיסטי שיצר אותה. השערת הייצוג האפלטוני (Huh et al., ICML 2024) מנסחת זאת: ככל שמודלים מתחזקים, הגיאומטריות הייצוגיות שלהם מתכנסות, אף בין מודליות. עדויות תומכות: Kornblith 2019 (CKA) — שכבות תואמות של רשתות נפרדות דומות, Git Re-Basin 2022 (אחרי יישור פרמוטציות, אימונים בלתי תלויים באותו אגן), model stitching (Bansal et al. 2021; Lenc & Vedaldi 2015) — שכבה ליניארית אחת מחברת רשתות בלתי תלויות בעונש קטן), ו-vec2vec 2025 (תרגום בין מרחבי embedding ללא זוגות בכלל, מהגיאומטריה לבדה).

### 2.3 ההשערה, בניסוח מדויק

מודלים בלתי תלויים ומאומנים היטב חולקים ייצוגים עד כדי טרנספורמציה ליניארית: קיימת מטריצה  $W$  כך ש- $f_B(x) \approx W \cdot f_A(x)$ . כל מילה נושאת משקל: 'מאומנים היטב' — הטענה חלה רק אחרי שהלמידה חילצה את מבנה הדאטה, ומכאן ביקורת המשקולות האקראיות. 'בלתי תלויים' — בלי אתחול או שושלת משותפים, אחרת הדמיון מורש ולא מתגלה. 'עד כדי ליניארית' — מחלקת הטרנספורמציה היא לב העניין: מתרגם לא-ליניארי שרירותי מרוקן את הטענה; דרישת זהות מפילה אותה טריוויאלית; ליניארי הוא נקודת האיזון — חזק דיו לבטל סיבובים ופרמוטציות, חלש מכדי לייצר מידע שאינו קיים. תת-טענה חזקה יותר — יישור בסיבוב טהור (Procrustes) — נבחנת גם היא.

### 3. ניסוי A — מבחן מדעי: GPT-2 מול Pythia-160M

#### 3.1 תכנון

זוג המודלים נבחר כך שכל דמיון יהיה לא-טריוויאלי: (2019, WebText, BPE) GPT-2 מול Pythia-160M (2023, The Pile), ארכיטקטורת tokenizer (GPT-NeoX, שונה) — שניהם מאומנים מאפס. במקרה לשניהם 13 hidden states בממד 768, המאפשר התאמת שכבות אחד-לאחד. הביקורת: מודל בארכיטקטורת Pythia עם משקולות אקראיות טריות — אותה ארכיטקטורה ואותם קלטים, אפס למידה — כך שהפער random-מינוס-trained מבודד את האפקט הסיבתי של הלמידה. שלושה שלבים: A1 חילוף אקטיביציות (10,000 קטעי WikiText-103, mean pooling לכל שכבה); A2 חישוב CKA לכל זוג שכבות; A3 תפירה ליניארית — מטריצת ridge אחת בצורה סגורה לכל זוג שכבות תואם, ומדידת  $R^2$  על held-out.

#### 3.2 ריצה ראשונה: תוצאה שלא הספיקה


הריצה הראשונה השתמשה ב-validation split — רק 1,646 קטעים. ה-CKA כבר הראה פער ברור (אלכסון 0.433 מול 0.087 אקראי), אבל התפירה נפלה מתחת לקריטריון שנקבע מראש ( $R^2 > 0.7$ ) בשכבות אמצעיות): ממוצע 0.434, שיא 0.552. לפני קבלת המסקנה החלשה נבדק גורם מבלבל: התאמת מטריצה  $768 \times 768$  (כ-590 אלף פרמטרים) על כ-1,234 שורות — יחס דיגמות-לממד של 1.6. במשטר כזה ה-ridge נאלץ לכווץ בחוזקה, וכיווץ זה מטה את ההערכה כלפי מטה באופן שיטתי. שימו לב לערכי ה- $R^2$  השליליים של הביקורת האקראית — התאמה מורעבת מכלילה גרוע יותר מניבוי הממוצע. ההשערה לא נכשלה; המדידה הייתה חסרת עוצמה.

#### 3.3 התיקון והשיפור

התרופה עלתה שינוי קוד אחד ו-15 דקות GPU: מעבר ל-train split והעלאת המדגם ל-10,000 (כ-10 דיגמות לממד). כל שאר הצינור נותר זהה, כך ששתי הריצות ברות-השוואה ישירה:

| מדד                   | ריצה 1 (1,646) | ריצה 2 (10,000) | שינוי       |
|-----------------------|----------------|-----------------|-------------|
| $R^2$ ממוצע (trained) | 0.434          | 0.737           | +0.303      |
| $R^2$ שיא (L11)       | 0.552          | 0.797           | +0.245      |
| טווח שכבות אמצעיות    | 0.55–0.41      | 0.80–0.70       | חוצה את 0.7 |
| $R^2$ ממוצע (random)  | -0.773         | 0.173           | התייצב      |
| פסיקה מול הקריטריון   | מתחת ליעד      | עובר            | —           |

טבלה 1: אפקט תיקון הרעבת הדיגמות — צינור זהה, פי 6 דאטה.




איור 1: תפירה ליניארית לפי שכבה, לפני (שמאל) ואחרי (ימין) תיקון גודל המדגם. כחול כהה — trained; אפור — ביקורת אקראית; מקווקו — סף ההצלחה 0.7.


גם הביקורת האקראית זזה (-0.77 ל-+0.17), בכיוון החזוי תיאורטית: עם דאטה מספק, ridge מנצל את הקורלציות השיריות שדולפות אף דרך שכבות אקראיות, בעיקר בשכבה 0 (0.375) הנשלטת על ידי סטטיסטיקת ה-embedding הגולמית. מה שקובע הוא המבנה: העקומה המאומנת עולה עם העומק (0.59 עד 0.80) בעוד האקראית דועכת מונוטונית (0.38 עד 0.09) — פער פי 8 בשכבה 11, בשיפועים הפוכים. הלקח המתודולוגי: הערכה חסרת עוצמה אינה מוסיפה רעש סימטרי — היא מייצרת מסקנות פסימיות-שיטתיות שנראות סבירות, ללא שום הודעת שגיאה.

### 3.4 תוצאות סופיות

CKA (10,000 דגימות): ממוצע trained מול-0.359, אלכסון 0.424, מקסימום 0.744; מול random — ממוצע 0.067, מקסימום 0.299. אפקט למידה של פי 4-5, יציב בין הריצות (CKA רעב לדאטה הרבה פחות מרגרסיה). שכבות הקצה נמוכות מסיבות עקרוניות: שכבה 0 היא טבלת embedding תלוית-tokenizer, והשכבה האחרונה מתמחה מחדש לראש הפלט של כל מודל.



איור 2: מפת החום של ה-CKA — הפלט האמיתי של הניסוי (ריצה 2). משמאל: מול Pythia מאומן, כל זוגות השכבות; הרצועה האלכסונית הבהירה מראה ששכבות מוקדמות תואמות ומוקדמות ואמצעיות לאמצעיות — המודלים מפתחים את אותו תוכן באותו סדר לאורך העומק. מימין: מול GPT-2 מלא Pythia במשקולות אקראיות בתנאים זהים — כהה אחיד. הניגוד זה-לצד-זה הוא הצורה הוויזואלית של הטיעון כולו: המבנה משמאל קיים רק בזכות הלמידה.



איור 3: סיכום CKA בשתי הריצות — פער הלמידה יציב בין גדלי מדגם.

| R <sup>2</sup> (random) | R <sup>2</sup> (trained) | זוג שכבות |
|-------------------------|--------------------------|-----------|
|-------------------------|--------------------------|-----------|

|       |       |                  |
|-------|-------|------------------|
| 0.375 | 0.590 | L0 (embeddings)  |
| 0.208 | 0.733 | L3               |
| 0.157 | 0.744 | L5               |
| 0.117 | 0.779 | L8               |
| 0.090 | 0.797 | L11 (שיא)        |
| 0.091 | 0.739 | L12 (פלט)        |
| 0.173 | 0.737 | ממוצע (13 שכבות) |

טבלה 2:  $R^2$  סופי של מפה ליניארית אחת בצורה סגורה, לכל זוג שכבות.

**פסיקה: ההשערה מאוששת בצורתה הכמותית החזקה** — מטריצה בודדת, מותאמת בצורה סגורה, מתרגמת 74%-80 מהשונות הייצוגית בין שתי רשתות שאינן חולקות דבר מלבד המשימה והעולם.

## 4. ניסוי B — יישום מעשי: מתאם MobileCLIP אל SigLIP

### 4.1 מהו וקטור/מטריצת המתאם

ה'מתאם' הוא מטריצה אחת  $W$  בגודל  $768 \times 512$ . הטלפון מקודד תמונה עם MobileCLIP-S1 לווקטור  $v$  בממד 512; הכפלה אחת  $W \cdot v$  (מיקרו-שניות על ה-Neural Engine; 1.6MB ב-0.79MB / fp32) נותנת וקטור בממד 768 שמתנהג כאזרח מן המניין במרחב SigLIP 2. ההתאמה נעשית בצורה סגורה ב-ridge על 3,000 זוגות (embedding של MobileCLIP, embedding של SigLIP) של אותן תמונות — בלי אימון גרדיאנטים, בלי לגעת באף מקודד. רק embeddings של תמונות מתורגמים, ורק בכיוון אחד: שאליות טקסט מקודדות תמיד בצד השרת על ידי SigLIP עצמו, שאינו מודע לקיום המתאם.


### 4.2 צינור

B1 מחלץ זוגות עבור 4,000 תמונות COCO val2017 ואת embeddings הטקסט של הכיתובים (mob\_img בגודל  $512 \times 4000$ , sig\_img ו-sig\_txt בגודל  $768 \times 4000$ ). בדיקת שפיות אישרה קוסינוס אלכסוני תמונה-כיתוב של 0.150 ב-SigLIP — בטווח הצפוי 0.1-0.3 למודלי B2. שני מתאמים בצורה סגורה — ridge (ליניארי מלא) ו-Procrustes (סיבוב טהור) — על חלוקת 3000/1000. B3 מודד את הקריטריון התפעולי: אחזור טקסט-לתמונה דרך המתאם מול תקרת SigLIP ומול baseline ללא מתאם. B2-bis מוסיף השוואה לא-ליניארית מבוקרת: MLP דו-שכבתי (early stopping. B4 שואמן epochs 300 ישירות על cosine loss עם GELU, 768-ל-1024 ל-512 Core ML מייצא ל-Core ML).

### 4.3 תוצאות — ורגע שני מתחת ליעד

| קוסינוס ממוצע ליעד | $R^2$ על held-out | גרסת מתאם               |
|--------------------|-------------------|-------------------------|
| 0.900              | 0.592             | Ridge (ליניארי מלא)     |
| 0.775              | 0.038             | Procrustes (סיבוב בלבד) |
| 0.903              | —                 | MLP (לא-ליניארי)        |

טבלה 3: איכות התאמת המתאם (1,000 תמונות held-out).



איור 4: שחזור כיוון לפי מחלקת מתאם. הפער +0.003 בין ליניארי ללא-ליניארי הוא הקריאה המדעית המרכזית.

הסתירה-לכאורה בין  $R^2$  צנוע (0.592) לקוסינוס גבוה (0.900) נפתרת בהתאמת מדד לשאלה:  $R^2$  מעניש שגיאות גודל (magnitude) שנרמול L2 ממילא זורק; קוסינוס מודד את הדבר היחיד שהאינדקס משתמש בו — כיוון. הערכת האחזור הראשונה הניבה את הרגע השני מתחת ליעד בפרויקט:


| R@10 | R@5 | R@1 | גרסת אחזור |
|------|-----|-----|------------|
|------|-----|-----|------------|

|       |       |           |                              |
|-------|-------|-----------|------------------------------|
| 0.944 | 0.885 | 0.630     | A. SigLIP מקורי (תקרה)       |
| 0.918 | 0.843 | 0.557     | B. MobileCLIP + מתאם ליניארי |
| 97.2% | 95.3% | 88.4%     | B כאחוז מהתקרה               |
| עובר  | עובר  | מתחת ליעד | שער (+90% מהתקרה)            |

טבלה 4: הערכת אחזור ראשונה —  $R@5/R@10$  עוברים;  $R@1$  מחמיץ ב-1.6 נקודות (כ-10 שאליות מתוך 1,000).

## 4.4 ניסיון השיפור — ומה שכישלוננו הוכיח

לפי טבלת ההחלטות שהוגדרה מראש (70%-90% מהתקרה — שדרג את המתאם), אומן MLP דו-שכבתי (כ-1.3 מיליון פרמטרים) ישירות על מטרת האחזור, עם אותה חלוקת train/eval בדיוק. התוצאה חד-משמעית באופן בלתי צפוי: קוסינוס מיטבי 0.9027 מול 0.900 של המפה הליניארית (+0.003), התכנסות עד epoch 30, ואחזור ללא שינוי סטטיסטי ( $R@1$  0.551;  $R@10$  0.926, 98.1% מהתקרה).



איור 5: תוצאות אחזור, כל הגרסאות. האחוזים מעל העמודות — המתאם הליניארי כשבר מהתקרה; אדום — baseline ללא מתאם ברמת מקריות.

ה'שיפור שנכשל' הוא התוצאה האינפורמטיבית ביותר בניסוי B: מודל בעל קיבולת גבוהה יותר, שמיטב את המטרה האמיתית, לא מצא דבר מעבר למפה הליניארית — ולכן הקשר בין המרחבים ליניארי במדויק, והפער השיורי ב- $R@1$  אינו כשל תרגום אלא מידע שהמקודד הניידי בממד 512 מעולם לא קידד. שום מתאם, בכל קיבולת, אינו יכול לשחזר מה שנעדר מהקלט; הגענו לתקרת הייצוג של המודל הקטן, לא של המתאם. הדבר משקף את מסקנת ניסוי A מהכיוון ההפוך: שם, יותר דאטה הוכיח שהמפה הליניארית טובה משנראתה; כאן, יותר קיבולת הוכיחה שהיא כבר אופטימלית. וממצא שלישי — קריסת Procrustes ל- $R^2$  של 0.038 — מעדן את התמונה: בניגוד לזוג מודלי השפה, מרחבים אלה נבדלים באנאיזטרופיה ולא רק בכיוון, ולכן סיבוב לבדו אינו מספיק.

## 4.5 החלטה הנדסית

המתאם הליניארי נכנס לייצור.  $R@5/R@10$  ברמת 95%-98% מהתקרה פירושם שתמונות שאונדקסו בטלפון אינן ניתנות להבחנה, בממשק רשת-תוצאות, מתמונות שאונדקסו בשרת. פער ה- $R@1$  (88.4%) הוא מחיר הרצת מקודד של 30MB במקום 1.5GB — מחיר שמשולם עם או בלי אינדקס משותף — ויש לו פתח מילוט זול: דירוג-מחדש שרתי של 10 המועמדות המובילות משחזר את התקרה במדויק. הארטיפקט הפרוס: חבילת Core ML של 0.79MB (MatMul + נרמול L2) שעברה את מלוא צינור ההמרה של coremltools.

## 4.6 ארגז חול איכותני: צינור הטלפון על מקרים חיים (שלב B5)

ארגז חול איכותני הדמה את המסלול המלא טלפון-אל-שרת על עשר תמונות COCO עם שאילתות טקסט חופשי: אותן משקולות MobileCLIP שהטלפון היה מריץ, המתאם מופעל ב-fp16 בדיוק כפי שחבילת ה-Core ML מחשבת, ושאילתות טקסט של SigLIP מחפשות בווקטורים המתקבלים (הכיתובים לעולם אינם מאונדקסים — רק פיקסלים). שאילתות ישירות אחזרו את מטרותיהן בדירוג 1 עם פערים מכריעים; שאילתות קומפוזיציוניות הדורשות הפשטה סמנטית (striped animals — המילה זברה אינה מופיעה בשאילתה — מקום 1 בפער פי 25 מביקורת השלילה) אישרו שמשמעות, ולא מילות מפתח, שורדת את התרגום הבין-מודלי; ביקורת שלילה (a dog, שנעדר מהגלריה) הניבה כנדרש פרופיל דמיון שטוח (פער מקום 1 של 0.004 מול 0.101 בשאילתה חיובית); וקוונטיזציית fp16 הוכחה כנייטרלית לדירוג (קוסינוס מינימלי 0.9999999 מול fp32) — וסגרה את המחצית המספרית של בדיקת ההתאמה ל-Core ML שנותרה פתוחה בשלב B4. גלריה אקראית שנייה, זרה לראשונה, שחזרה את הדפוס — דירוג עליון נכון לשאילתות חיוביות ופרופיל שטוח לשאילתה ללא תשובה תקפה (a vehicle: דמיון מקום 1 של 0.022 מול 0.106 לפגיעות) — מה שמעיד שההתנהגות היא תכונה של הצינור, לא של מדגם מסוים. שני כמעט-ההחטאות שנצפו — ניסוחים עקיפים שאיבדו את מקום 1 בפער של 0.007 או פחות תוך הישארות במקום 2 — משחזרים, ברמת השאילתה הבודדת, בדיוק את פרופיל ה-R@1/R@5 שנמדד כמותית בשלב B3, ואלה המקרים שדירוג-מחדש שרתי אופציונלי משחזר. דמו אינטראקטיבי המשך (שלב B6) הריץ את לולאת המוצר המלאה בשידור חי: תמונת משתמש שהועלתה לשכבת המובייל אונדקסה דרך מסלול הטלפון ב-39ms, קוטלגה אוטומטית, ואוחזרה במקום 1 על ידי שאילתת הטקסט החופשי singing red bird — מדורגת באותה רשימת תוצאות עם תמונות שאונדקסו בשרת — כשחיפוש מקומי אורך 0.08ms מול 150ms בסבב רשת (מדומה): אינדקס אחד, שתי שכבות, מהיר מדידית מקומית.

## 5. מה חדש כאן — הערכה כנה

תיאוריה: שחזור בלתי תלוי, לא תגלית חדשה. הרכיבים המדעיים משחזרים תוצאות מבוססות בקנה מידה קטן (Kornblith 2019, Bansal 2021, PRH 2024). ערכו של ניסוי A הוא של רפליקציה בלתי תלויה וקפדנית על זוג מודלים 'עוין' במכוון, עם ביקורת נכונה — בתוספת אבחון הרעבת הדגימות המתועד, תרומה מתודולוגית מעשית.

פרקטיקה: יישום נדיר באמת. הצירוף בניסוי B אינו דפוס מפורסם מבוסס: גשר ליניארי בצורה סגורה בין שני מקודדי ייצור הטרוגניים (MobileCLIP-S1 אל SigLIP 2), מאומת באחזור-מטרה מול תקרה ומקריאות, כולל הדגמה מבוקרת שאי-ליניאריות אינה מוסיפה דבר, ופרוס כארטיפקט Core ML תת-מגה-בייט המאפשר אינדקס וקטורי משותף בין טלפון צרכני לשרת. תרגום embeddings בין מודלים קיים במחקר; אריזתו כרכיב תשתית נושא-עומס ומדוד של מערכת דו-שכבתית — עם פרטיות, אינדוקס אופליין וכלכלת אינדקס-יחיד כתמורה — היא התרומה המעשית של הפרויקט.

טענות שבמפורש אינן נטענות: הפרויקט אינו מוכיח שניתן להשתיל שכבות בין ארכיטקטורות (סימטריית הפרמוטציה עדיין אוסרת), אינו מבסס התכנסות מעבר להתפלגויות שנבחנו, ואינו טוען שהמתאם משחזר מידע שנעדר מהמקודד הקטן.

## 6. אתגרים שנפתרו בדרך

יומן הפרויקט הוא גם מקרה בוחן בהנדסת ML בעולם האמיתי: (1) ספריית datasets של HuggingFace הוציאה משימוש מבוסס-סקריפט באמצע הפרויקט ושברה גם את WikiText וגם שני מקורות Flickr; נפתר במעבר ל-parquet (Salesforce/wikitext) ולהורדות COCO רשמיות ישירות. (2) שינוי API ב-transformers גרם לפונקציות ה-features של SigLIP להחזיר אובייקטים במקום טנסורים; נפתר ב-shim אגנוסטי-גרסה. (3) מודל ה-VM-לכל-notebook של Colab מחק בשקט תוצרי שלבים; נפתר במוסכמת DATA\_DIR מגובה Google Drive ההופכת כל שלב לחסר-מצב. (4) הטיית הרעבת הדגימות — הבאג המשמעותי מדעית ביותר, כי ייצר מסקנות שגויות

שנראות סבירות ולא הודעת שגיאה. (5) פרשנות מדדים נכונה:  $R^2$  מול קוסינוס, האינפורמנטיות של CKA, ומדוע למודלי sigmoid-loss קוסינוסים אבסולוטיים נמוכים.

## 7. תכולת הפרויקט ואופן הרצה

שבעה notebooks עצמאיים (אחד לשלב), כל אחד עם markdown באנגלית המסביר מטרה, שיטה, פלט צפוי וקריטריוני הצלחה, ואחריו קוד רץ: A1-A3 ו-B1-B4; לצידם סקריפטים מקבילים ו-PROJECT\_GUIDE.md מרכז. מודלים: Pythia-160M, GPT-2, ביקורת Pythia אקראית, MobileCLIP-S1 (דרך open\_clip), SigLIP 2 base. דאטה: WikiText-103 (10 אלף קטעים), COCO val2017 (4 אלף זוגות). האימון היחיד בכל הפרויקט: התאמות ridge בצורה סגורה וה-MLP ההשוואתי המבוקר; כל מודלי הבסיס קפואים. סביבה: כל Jupyter עם GPU (פותח על T4 Colab, מספיק). כל notebook נפתח בתא אחסון — ב-Colab יש להעלות Drive ולהגדיר DATA\_DIR לנתיב בו, כדי שתוצרי שלבים ישרדו מיחזור VM. סדר זמנים: A1 (כ-15 דקות GPU), A2, A3 (שניות); B1 (כ-10 דקות), B2-B4 (שניות). עלות כוללת: פחות משעת GPU אחת. לתיעוד: את PROJECT\_GUIDE, הדוח וה-markdown של ה-notebooks ניתן להעלות כמקורות ל-NotebookLM לשאלות-תשובות וסיכומי לימוד; נתיב ההרצה עצמו הוא ה-notebooks ב-Colab.

## 8. סיכום

שאלה פילוסופית — האם מודלים יכולים לחלוק את מה שלמדו ללא אימון מחדש? — זוקקה להשערה בת-הפרכה, נבחנה עם ביקורות נאותות, אוששה כמותית (74%-80% מהשונות הייצוגית מתורגמת במטריצה אחת בצורה סגורה בין מודלי שפה בלתי תלויים לחלוטין), והומרה לרכיב תשתית מדוד ופרוס: מתאם Core ML של 0.79MB המאפשר לטלפון ולשרת, המריצים מקודדים שמעולם לא נפגשו, לכתוב ולחפש באינדקס וקטורי משותף אחד ברמת 95%-98% מאיכות האחזור של המודל הגדול. חוט השדרה של שני הניסויים הוא משפט אחד: מודלים שאומנו באופן בלתי תלוי מגלים את אותו מבנה של העולם, בקואורדינטות שונות — ושער החליפין בין הקואורדינטות הוא מטריצה אחת. ארגז חול חי (B5) סגר את המעגל איכותני: על פני שתי גלריות תמונות זרות, שאילתות טקסט שרתיות אחזרו נכונה תמונות שאונדקסו בטלפון — כולל שאילתות קומפוזיציוניות ותגובות שטוחות-כנדרש כשלא הייתה תשובה תקפה — כשקוונטיזציית fp16 מוכחת כנייטרלית לדירוג.